

Рубежный контроль №1 (весна 2026)

Тема: Технологии разведочного анализа и обработки данных

Вариант: 16

Задание: 2 — обработка пропусков (категориальный и количественный признак)

Датасет: Boston Housing (`HousingData.csv`)

Студент: Рубинштейн И.А.

Группа: ИУ5-63Б

Цель работы

Для набора данных Boston Housing необходимо: **выбрать один категориальный и один количественный признак с пропусками**, применить к ним **разные стратегии заполнения** пропусков, пояснить выбор методов для категориальных и числовых признаков, обосновать набор признаков для последующего обучения моделей машинного обучения, а также **построить boxplot** (для групп ИУ5-63Б, ИУ5Ц-83Б).

Загрузка данных и краткий обзор

Пропуски в файле обозначены как `NA`.

```
In [8]: import pathlib

import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
from IPython.display import display

ROOT = pathlib.Path.cwd()
candidates = [
    ROOT.parent / "data" / "HousingData.csv",
    ROOT / "data" / "HousingData.csv",
    ROOT / "HousingData.csv",
]
CSV_PATH = next((p for p in candidates if p.exists()), None)
if CSV_PATH is None:
    raise FileNotFoundError(
        "Положите ноутбук в папку version_16 или укажите путь к data/HousingData.csv"
    )

df_raw = pd.read_csv(CSV_PATH, na_values=["NA", ""])
print("Файл: HousingData.csv")
```

```
print("Размерность:", df_raw.shape)
df_raw.head()
```

Файл: HousingData.csv

Размерность: (506, 14)

```
Out[8]:
```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT
0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1	296	15.3	396.90	
1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2	242	17.8	396.90	
2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2	242	17.8	392.83	
3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3	222	18.7	394.63	
4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.0622	3	222	18.7	396.90	

```
In [9]: df_raw.dtypes
```

```
Out[9]: CRIM      float64
ZN          float64
INDUS       float64
CHAS        float64
NOX         float64
RM          float64
AGE         float64
DIS         float64
RAD          int64
TAX          int64
PTRATIO     float64
B           float64
LSTAT       float64
MEDV       float64
dtype: object
```

Анализ пропусков

Посчитаем число пропусков по столбцам и выберем признаки с ненулевым числом

NA : для категориального примера удобен **CHAS** (фиктивная переменная границы с рекой Чарльз — бинарный признак, в модели обычно трактуется как категориальный номинальный), для количественного — **LSTAT** (доля населения с «низким статусом»). В данном **HousingData.csv** у **RM** пропусков нет — поэтому демонстрация медианы делается именно по **LSTAT** ; иначе фильтр по **RM.isna()** даёт пустую таблицу.

```
In [10]: miss = df_raw.isna().sum().sort_values(ascending=False)
print("Столбцы с пропусками:")
print(miss[miss > 0])
rows_any = df_raw.isna().any(axis=1).sum()
print("\nСтрок с хотя бы одним NA:", int(rows_any))
print("NA по CHAS:", df_raw["CHAS"].isna().sum(), "NA по LSTAT:", df_raw["LSTAT"].i
```

Столбцы с пропусками:

```
CRIM      20
ZN        20
INDUS     20
CHAS      20
LSTAT     20
AGE       20
dtype: int64
```

Строк с хотя бы одним NA: 112

NA по CHAS: 20 NA по LSTAT: 20

Категориальный признак CHAS — заполнение модой

Для **категориальных** признаков (включая бинарный «есть только класс 0 или 1») распространённый способ — заменить пропуски **наиболее частой категорией (моду)** среди наблюдавшихся значений. Это сохраняет распределение «типичного» района и масштаб категории. Альтернативой была бы отдельная метка («неизвестно»); здесь ограничимся условием задания одним явным способом — **mode imputation**.

```
In [11]: CAT_COL = "CHAS"
chas_mode = df_raw[CAT_COL].mode(dropna=True).iloc[0]
print("Мода CHAS среди наблюдаемых:", float(chas_mode))

df_imp = df_raw.copy()
df_imp[CAT_COL] = df_imp[CAT_COL].fillna(chas_mode)

chk = (
    df_raw.loc[df_raw[CAT_COL].isna(), [CAT_COL]].assign(
        after_fill=df_imp.loc[df_raw[CAT_COL].isna(), CAT_COL].values
    )
    .head(10)
)
print("Фрагмент: было NA для CHAS → после моды:")
display(chk)
```

Мода CHAS среди наблюдаемых: 0.0

Фрагмент: было NA для CHAS → после моды:

	CHAS	after_fill
6	NaN	0.0
9	NaN	0.0
14	NaN	0.0
43	NaN	0.0
119	NaN	0.0
152	NaN	0.0
206	NaN	0.0
240	NaN	0.0
245	NaN	0.0
254	NaN	0.0

Количественный признак LSTAT — заполнение медианой

Для **числовых** признаков распространены **среднее** и **медиана** по столбцу. Выбрана **медиана** по **LSTAT**: она устойчива к выбросам по сравнению со средним и в этом датасете в столбце действительно есть пропуски (в отличие от **RM**, где в нашем файле NA нет).

```
In [12]: NUM_COL = "LSTAT"
lstat_med = df_raw[NUM_COL].median(skipna=True)
print(f"Медиана LSTAT среди наблюдаемых значений (без NA): {lstat_med:.4f}")

df_imp[NUM_COL] = df_imp[NUM_COL].fillna(lstat_med)

chk_num = (
    df_raw.loc[df_raw[NUM_COL].isna(), [NUM_COL]]
    .assign(after_fill=df_imp.loc[df_raw[NUM_COL].isna(), NUM_COL].values)
    .head(10)
)
print("Фрагмент: было NA для LSTAT → после медианы:")
display(chk_num)
```

Медиана LSTAT среди наблюдаемых значений (без NA): 11.4300
Фрагмент: было NA для LSTAT → после медианы:

	LSTAT	after_fill
4	NaN	11.43
35	NaN	11.43
73	NaN	11.43
79	NaN	11.43
87	NaN	11.43
116	NaN	11.43
207	NaN	11.43
226	NaN	11.43
228	NaN	11.43
271	NaN	11.43

Набор без пропусков для последующего моделирования

После **целевой** импутации столбцов **CHAS** и **LSTAT** в других столбцах набора могут оставаться **NA**. Для обучения классической регрессии по **MEDV** нужна полная числовая матрица наблюдений без «дыр». Здесь **остальные пропуски устраняются удалением строк** (`dropna`). Число отброшенных строк ниже напечатаем.

```
In [13]: before = df_imp.shape[0]
df_ml = df_imp.dropna(how="any").copy()
after = df_ml.shape[0]
print(
    f"Строк до dropna после импутации CHAS/LSTAT: {before}, после: {after}, удалено
")
print("Пропусков в df_ml:", df_ml.isna().sum().sum())
df_ml.head()
```

Строк до dropna после импутации CHAS/LSTAT: 506, после: 430, удалено 76
Пропусков в df_ml: 0

```
Out[13]:
```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	I
0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1	296	15.3	396.90	
1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2	242	17.8	396.90	
2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2	242	17.8	392.83	
3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3	222	18.7	394.63	
4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.0622	3	222	18.7	396.90	

Способы обработки пропусков — краткое резюме

Тип признака	Выбранный столбец	Способ
Категориальный	CHAS	замена модой наблюдавшихся значений
Количественный	LSTAT	замена медианой по столбцу
Прочие пропуски	все остальные столбцы	удаление строк с оставшимся NA

Почему не одна универсальная схема. Категориальные коды без естественного порядка плохо заполнять «средним» числом моды интерпретируются как классическая метка режима номинальных данных. Количественные столбцы дискретных и связанных переменных (как среднее число комнат) хорошо подходят под устойчивую к выбросам **медиану**. Дальнейшие проекты могут использовать `SimpleImputer`, MICE или предсказывающие модели импутации — они выходят за минимальный объём этого задания.

Какие признаки использовать при построении моделей машинного обучения и почему

Цель (таргет): столбец `MEDV` — медианная стоимость жилья; задача регрессии.

Признаки (вход): после очистки — все столбцы, кроме `MEDV`: `CRIM`, `ZN`, `INDUS`, `CHAS`, `NOX`, `RM`, `AGE`, `DIS`, `RAD`, `TAX`, `PTRATIO`, `B`, `LSTAT`. Они характеризуют криминогенность, зонирование, промышленную застройку, экологический фактор, размер домов и районные показатели — это содержательно связано со стоимостью недвижимости.

О переменной `CHAS`: бинарный индикатор; можно оставить как 0/1 для деревьев и линейных моделей без порядкового искажения между двумя уровнями; при желании возможен one-hot без изменения информации для двух уровней.


Осторожность: между частью признаков (например, `RAD` и `TAX`) высока линейная корреляция; для линейной регрессии может понадобиться регуляризация или отбор признаков; для случайного леса и Gradient Boosting эффект иной. Это уже этапы модельного блока после корректной подготовки данных.

Дополнение для группы ИУ5-63Б — ящик с усами (boxplot)

Построена диаграмма размаха для произвольного числового признака `RM` по очищенному набору `df_m1`.

```
In [14]: BOXPLOT_COL = "RM"

plt.figure(figsize=(7, 4))
sns.boxplot(data=df_ml, y=BOXPLOT_COL, color="C0")
plt.title(f"Boxplot: {BOXPLOT_COL}")
plt.ylabel(BOXPLOT_COL)
plt.tight_layout()
plt.show()
```



Выводы

В работе выполнена **прикладная** обработка пропусков: для **CHAS** использованы **режимные категории (мода)**, для **LSTAT** — **медиана** остальных значений столбца. Дальнейшие пропуски устранены **удалением строк**, что даёт множество **df_ml** без пропусков и пригодное для базового обучения регрессии по **MEDV**. Построен **boxplot** по **RM** для диагностики распределений и возможных выбросов перед моделированием.